

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG
— o0o —



Báo cáo Project 1

Tên đề tài: Fine-tuning mô hình LLM

Giảng viên hướng dẫn : Nguyễn Hoàng Long

Sinh viên thực hiện : Nguyễn Thế Thành

MSSV : 20235432

Hà Nội - 2026

Mục lục

1. Phương pháp	3
2. Kết quả	3

1. Phương pháp

Phương pháp được trình bày chi tiết trong file: `project1_fine-tuning_llm.ipynb`.

Link github: [project1_fine-tuning_llm.ipynb](#).

2. Kết quả

Ta sử dụng `lm_eval` với các benchmark cơ bản như ARC-Easy, HellaSwag, BoolQ và thu được kết quả như hình dưới:

```
BASE: {'arc_easy': 0.6178451178451179, 'hellaswag': 0.6419040031866162, 'boolq': 0.6376146788990825}
LoRA: {'arc_easy': 0.6292087542087542, 'hellaswag': 0.6490738896634136, 'boolq': 0.6443425076452599}
FULL: {'arc_easy': 0.6127946127946128, 'hellaswag': 0.6549492133041227, 'boolq': 0.6461773700305811}
```

Nhận xét với từng benchmark:

- **ARC-Easy (Reasoning cơ bản, kiến thức phổ thông):** LoRA fine-tuning giúp cải thiện rõ rệt độ chính xác so với mô hình gốc, trong khi full fine-tuning lại không mang lại lợi ích, thậm chí giảm nhẹ hiệu năng. Điều này cho thấy với các tác vụ reasoning đơn giản như ARC-Easy, việc cập nhật toàn bộ tham số có thể dẫn đến overfitting hoặc làm suy giảm kiến thức nền ban đầu của mô hình.
- **HellaSwag (Common-sense reasoning):** Cả hai phương pháp fine-tuning đều cải thiện hiệu năng so với BASE, trong đó full fine-tuning đạt kết quả tốt nhất. Điều này cho thấy với các bài toán đòi hỏi suy luận theo ngữ cảnh và chuỗi hành động, việc cập nhật toàn bộ tham số giúp mô hình thích nghi tốt hơn với dữ liệu huấn luyện mới.
- **BoolQ (Hiểu văn bản, với tập dữ liệu yes/no question):** Xu hướng tương tự HellaSwag: cả LoRA và FULL đều cải thiện so với BASE, trong đó full fine-tuning đạt kết quả cao nhất. Điều này cho thấy fine-tuning giúp mô hình cải thiện khả năng nắm bắt ngữ nghĩa, vốn phụ thuộc nhiều vào sự tinh chỉnh trọng số.